

E-commerce Product Analytics

Анализ продуктовых метрик, повторных покупок
и результатов А/В-теста

Инструменты:

SQL, MySQL/MariaDB, Python, pandas, matplotlib, scipy, statsmodels, DBeaver.

Репозиторий проекта:

<https://github.com/mantven/product-analytics-funnel-retention-ab-testing>

Contents

1	Описание проекта	2
2	Исходные данные	3
3	Подготовка данных	3
4	Ограничения исходных данных	4
5	Ежемесячные продуктовые показатели	4
5.1	Выручка	5
5.2	Количество покупок	6
5.3	Средний чек	7
6	Анализ покупателей	8
6.1	Разовые и повторные покупатели	9
7	Время до второй покупки	10
8	Когортный анализ	11
9	А/В-тест	12
9.1	Основные показатели	12
9.2	Проверка распределения пользователей	13
9.3	Статистическая проверка	13
9.4	Минимальный обнаруживаемый эффект	14
9.5	Необходимый размер выборки	14
10	Результаты А/В-теста по странам	15
11	Итоговые выводы	16
12	Ограничения анализа	17

1. Описание проекта

Цель проекта — проанализировать пользовательские события интернет-магазина, рассчитать основные продуктовые показатели, изучить повторные покупки и проверить результаты А/В-теста новой версии посадочной страницы.

В рамках проекта были выполнены следующие этапы:

1. Загрузка исходных данных в MySQL/MariaDB.
2. Проверка пропусков, дубликатов и типов данных.
3. Создание очищенных таблиц.
4. Расчёт ежемесячных продуктовых показателей.
5. Анализ частоты и сроков повторных покупок.
6. Когортный анализ покупателей.
7. Очистка данных А/В-теста.
8. Проверка распределения пользователей между группами.
9. Статистическое сравнение конверсий.
10. Расчёт доверительного интервала, MDE и требуемой выборки.
11. Анализ результатов эксперимента по странам.
12. Построение визуализаций в Python.

2. Исходные данные

В работе использовались три набора данных:

- пользовательские события интернет-магазина;
- результаты А/В-теста;
- страны участников эксперимента.

Основной набор событий содержит следующие типы действий:

- посещение;
- просмотр товара;
- добавление товара в корзину;
- переход к оформлению;
- покупка.

Для каждого события доступны идентификаторы пользователя и сессии, дата и время события, тип устройства, источник трафика, категория, товар и цена.

Набор А/В-теста содержит идентификатор пользователя, экспериментальную группу, версию страницы и факт конверсии.

3. Подготовка данных

После загрузки исходных файлов были созданы очищенные таблицы:

- `clean_user_events`;
- `clean_ab_data`;
- `clean_countries`;
- `ab_data_final`.

В таблице пользовательских событий было сохранено 320 000 строк. Текстовые поля были приведены к нижнему регистру, даты преобразованы в тип `DATETIME`, цены — в числовой формат.

Пропуски цены были обнаружены только у событий посещения и просмотра. Это соответствует структуре данных: денежное значение требуется только для событий, связанных с товаром и покупкой.

В данных А/В-теста были удалены:

- пользователи с несоответствием группы и версии страницы;
- повторные записи одного пользователя.

После очистки в А/В-тесте осталось 290 585 уникальных пользователей.

4. Ограничения исходных данных

Во время проверки данных были обнаружены ограничения, которые повлияли на выбор методов анализа.

Большинство сессий содержит только одно событие. Поэтому построение надёжной последовательной воронки на уровне сессии невозможно.

Идентификатор товара также не связан стабильно с одной категорией. Один и тот же идентификатор встречается в нескольких категориях. Поэтому товарная воронка не использовалась.

Последовательная воронка на уровне пользователя формировалась на слишком длинном временном интервале. Среднее время от первого посещения до покупки составляло несколько месяцев, а при ограничении окна тридцатью днями число покупок становилось слишком малым.

По этой причине в итоговом анализе использовались агрегированные продуктовые метрики, анализ покупателей, когортный анализ и отдельный набор А/В-теста.

Данные имеют признаки синтетического и равномерно сгенерированного набора. Это учитывалось при интерпретации результатов.

5. Ежемесячные продуктовые показатели

Для каждого месяца были рассчитаны:

- общее количество событий;
- количество активных пользователей;
- количество покупок;
- количество покупателей;
- выручка;
- средний чек;
- доля покупателей среди активных пользователей;
- среднее число событий на пользователя.

Выручка рассчитывалась как сумма цен событий покупки:

$$\text{Revenue} = \sum_{i=1}^n \text{Price}_i.$$

Средний чек рассчитывался как:

$$\text{Average Order Value} = \frac{\text{Revenue}}{\text{Number of Purchases}}.$$

5.1. Выручка

Месячная выручка находилась в диапазоне от 5,59 до 6,35 млн.

Минимальное значение наблюдалось в феврале, максимальное — в апреле. Устойчивого восходящего или нисходящего тренда не обнаружено.




Figure 1. Динамика месячной выручки

5.2. Количество покупок

Количество покупок менялось от 1 968 до 2 224 в месяц.

Минимальное значение было зафиксировано в феврале, максимальное — в октябре.

Снижение количества покупок в феврале, мае и ноябре совпадает со снижением выручки в эти месяцы.




Figure 2. Количество покупок по месяцам

5.3. Средний чек

Средний чек находился в диапазоне от 2 801 до 2 927.

Максимальное значение наблюдалось в марте, минимальное — в мае. Изменения среднего чека были менее выраженными, чем изменения количества покупок.




Figure 3. Средний чек по месяцам

Таким образом, месячные колебания выручки в большей степени связаны с количеством покупок, чем с изменением среднего чека.

6. Анализ покупателей

Всего покупателями стали 10 566 пользователей.

Распределение по количеству покупок представлено в таблице.

Table 1. Распределение покупателей по количеству покупок

Покупок	Покупателей	Доля, %
1	3 052	28,89
2	3 172	30,02
3	2 362	22,35
4	1 201	11,37
5	534	5,05
6	178	1,68
7	53	0,50
8	12	0,11
9	1	0,01
10	1	0,01

Наиболее многочисленная группа — пользователи с двумя покупками. Около 81,3% покупателей совершили не более трёх покупок.




Figure 4. Распределение покупателей по количеству покупок

6.1. Разовые и повторные покупатели

Разовыми считались пользователи, совершившие одну покупку. К повторным были отнесены пользователи с двумя покупками и более.

Table 2. Показатели по типу покупателя

Тип	Покупатели	Покупки	Выручка, млн	Доля выручки, %
Разовые	3 052	3 052	8,63	11,90
Повторные	7 514	22 458	63,91	88,10

Повторные покупатели составляют 71,1% покупателей и формируют 88,1% всей выручки. Средняя выручка на одного повторного покупателя примерно в три раза выше, чем на одного разового покупателя.

Этот результат является описательной связью. Он не доказывает, что увеличение количества повторных покупок автоматически вызовет пропорциональный рост выручки.




Figure 5. Доля выручки разовых и повторных покупателей

7. Время до второй покупки

Для каждого повторного покупателя был рассчитан интервал между первой и второй покупкой.

Среднее время до второй покупки составило 99,96 дня, медианное — 81 день.

Table 3. Срок совершения второй покупки

Период	Покупателей	Доля, %
В тот же день	30	0,40
1–7 дней	384	5,11
8–30 дней	1 242	16,53
31–60 дней	1 319	17,55
61–90 дней	1 116	14,85
Более 90 дней	3 423	45,55

В течение 30 дней вторую покупку совершили 22,04% повторных покупателей. В течение 90 дней вернулись 54,45%.

Почти половина повторных покупателей совершила вторую покупку позднее чем через 90 дней. Поэтому короткое окно наблюдения может заметно занижать оценку повторных покупок.




Figure 6. Распределение времени до второй покупки

8. Когортный анализ

Покупатели были разделены на когорты по месяцу первой покупки.

Для каждой когорты рассчитывалась доля пользователей, совершивших покупку в последующие календарные месяцы:

$$\text{Retention}_m = \frac{\text{Активные покупатели когорты в месяце } m}{\text{Размер когорты}} \cdot 100\%.$$

Месяц первой покупки обозначен как $M0$, следующий календарный месяц — как $M1$, далее $M2$, $M3$ и так далее.

В большинстве когорт месячный retention находился примерно в диапазоне 14–18%. Выявленного улучшения или ухудшения показателя между когортами не обнаружено.




Figure 7. Когортный retention покупателей

Пустые ячейки в правой части графика не означают нулевой retention. Соответствующие периоды отсутствуют из-за окончания наблюдаемого интервала.

Покупатели, совершившие первую покупку в конце года, имели меньше времени для повторной активности. Это ограничение необходимо учитывать при сравнении когорт.

9. А/В-тест

В эксперименте сравнивались старая и новая версии посадочной страницы. Контрольная группа видела старую страницу, тестовая группа — новую страницу. Нулевая гипотеза:

$$H_0 : p_{\text{treatment}} = p_{\text{control}}.$$

Альтернативная гипотеза:

$$H_1 : p_{\text{treatment}} \neq p_{\text{control}}.$$

Использовался двусторонний z-тест для двух долей с уровнем значимости

$$\alpha = 0,05.$$

9.1. Основные показатели

Table 4. Результаты А/В-теста

Группа	Пользователи	Конверсии	Конверсия, %
Control	145 274	17 489	12,0386
Treatment	145 311	17 264	11,8807

Абсолютная разница конверсий:

$$11,8807\% - 12,0386\% = -0,1579 \text{ п.п.}$$

Относительное изменение составило $-1,31\%$.




Figure 8. Конверсия контрольной и тестовой групп

9.2. Проверка распределения пользователей

Перед сравнением конверсий была выполнена проверка Sample Ratio Mismatch.

Ожидаемое распределение пользователей между группами составляло 50/50.

Результат проверки:

$$p\text{-value}_{SRM} = 0,9453.$$

Значение значительно превышает 0,05. Признаков нарушения распределения пользователей между группами не обнаружено.

9.3. Статистическая проверка

Результат z-теста:

$$z = -1,3116,$$

$$p\text{-value} = 0,1897.$$

Так как

$$0,1897 > 0,05,$$

нулевая гипотеза не отклоняется.

Статистически значимого различия между конверсиями контрольной и тестовой групп не обнаружено.

95%-й доверительный интервал для разницы конверсий:

$$[-0,3939; 0,0781] \text{ п.п.}$$

Интервал включает ноль. Реальный эффект может быть небольшим отрицательным, практически нулевым или слабо положительным.

9.4. Минимальный обнаруживаемый эффект

При уровне значимости 5% и мощности 80% эксперимент мог надёжно обнаружить изменение примерно от:

$$MDE = 0,3403 \text{ п.п.}$$

В относительном выражении:

$$MDE_{\text{relative}} = 2,8266\%.$$

Наблюдаемая разница составила только $-0,1579$ процентного пункта, что меньше рассчитанного MDE.

Это не доказывает полное отсутствие эффекта. Результат означает, что эксперимент не обладал достаточной чувствительностью для надёжного обнаружения настолько небольшого изменения.

9.5. Необходимый размер выборки

Для обнаружения наблюдаемой разницы при мощности 80% потребовалось бы:

- 662 801 пользователь в контрольной группе;
- 662 970 пользователей в тестовой группе;
- 1 325 770 пользователей всего.

Фактическая выборка составила 290 585 пользователей.

Для будущих экспериментов размер выборки следует рассчитывать заранее на основе минимального бизнес-значимого эффекта, а не на основе результата уже проведённого теста.

10. Результаты А/В-теста по странам

Дополнительно результаты были проверены отдельно для Канады, Великобритании и США.

Table 5. Эффект новой страницы по странам

Страна	Control, %	Treatment, %	Разница, п.п.
CA	11,8783	11,1902	-0,6881
UK	12,0022	12,1171	0,1149
US	12,0630	11,8464	-0,2166

После применения поправки Холма статистически значимого эффекта не обнаружено ни в одной стране.




Figure 9. Эффект новой страницы по странам

Для проверки различий эффекта между странами использовался тест Бреслоу–Джя. Результат:

$$p\text{-value} = 0,2915.$$

Оснований считать, что эффект новой страницы статистически различается между странами, нет.

Объединённое отношение шансов составило:

$$OR = 0,9852,$$

95%-й доверительный интервал:

$$[0,9633; 1,0075].$$

Интервал включает единицу, поэтому статистически подтверждённого общего изменения шансов конверсии нет.

11. Итоговые выводы

По результатам анализа были получены следующие выводы:

1. Ежемесячные продуктовые показатели в течение года были достаточно стабильными.
2. Выручка находилась в диапазоне 5,59–6,35 млн в месяц.
3. Месячные изменения выручки в большей степени связаны с количеством покупок, чем со средним чеком.
4. Повторные покупатели составляют 71,1% покупателей и формируют 88,1% выручки.
5. Медианное время до второй покупки составляет 81 день.
6. Только 22,04% повторных покупателей совершают вторую покупку в течение 30 дней.
7. Ежемесячный когортный retention в большинстве случаев находится примерно на уровне 14–18%.
8. Новая страница показала конверсию на 0,1579 процентного пункта ниже контрольной.
9. Полученная разница статистически незначима: $p\text{-value} = 0,1897$.
10. Доверительный интервал включает ноль, поэтому доказательств влияния новой страницы на конверсию нет.
11. Оснований внедрять новую страницу с целью повышения конверсии не обнаружено.
12. Для будущих экспериментов необходимо заранее рассчитывать размер выборки на основе бизнес-значимого эффекта.

12. Ограничения анализа

К основным ограничениям относятся:

- неполная временная метка в наборе А/В-теста;
- невозможность провести анализ динамики эксперимента по дням;
- отсутствие надёжной последовательной событийной воронки;
- большое число сессий только с одним событием;
- нестабильная связь идентификаторов товаров с категориями;
- признаки искусственно сгенерированных данных;
- правое цензурирование при анализе повторных покупок.

Несмотря на ограничения, набор данных позволяет продемонстрировать полный цикл продуктового анализа: от проверки качества данных и расчёта метрик до когортного анализа и статистической проверки А/В-теста.